Le vote pondéré de Golub peut-il classer des échantillons mammaires malins de façon précise et robuste ?

Étude sur le jeu de données Wisconsin Diagnostic Breast Cancer (WDBC)

Raphaël MARINO

Lien vers le GitHub : https://github.com/Cosybowl/MLBIO---Apply-a-published-method-to-a-new-dataset

1. Introduction et plan

Golub et al. (1999) ont montré qu'un petit nombre de gènes pondérés pouvait distinguer deux types de leucémie (ALL/AML). Leur méthode, le vote pondéré, donne un poids à chaque gène selon sa capacité à séparer les deux classes. Les gènes les mieux classés « votent » ensuite pour décider de la classe d'un nouvel échantillon.

La question est donc la suivante : est-ce que cette méthode marche aussi sur un autre type de données ?

Dans le projet, on l'applique à des tumeurs du sein. Les deux situations sont très différentes. De plus, les données sont différentes : seulement 30 mesures, très liées entre elles, avec des unités différentes. Il y a également plus d'échantillons (569).

Le rapport suit l'ordre de l'énoncé :

- Exploration des données
- Méthode et protocole d'évaluation
- Performances du vote pondéré
- Stabilité de la sélection de features
- Comparaison avec la régression logistique
- Conclusion clinique
- Reproductibilité du papier de Golub et al.
- Sources

2. Exploration des données

Cette étape sert seulement à décrire les données, elle n'a pas servi à choisir les mesures. Le choix est refait à chaque fois dans le jeu d'entraînement.

2.1 Taille et structure

Le fichier contient 569 patientes (une ligne = une patiente) et 30 features numériques, sans valeur manquante. Les colonnes d'identifiant (sample_id) sont retirées avant toute analyse car elles ne portent aucune information biologique et pourraient biaiser un modèle (on peut avoir des informations sur une patiente en liant l'id par exemple).

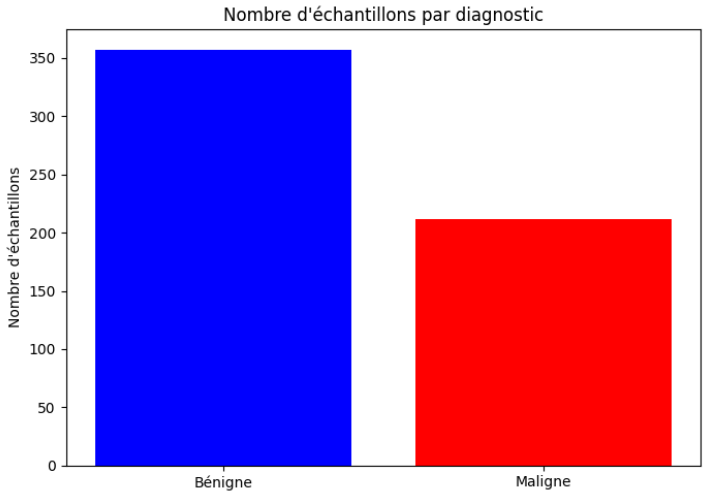


Figure 1 - Effectifs par diagnostic (357 bénignes, 212 malignes)

J'ai pu relever 212 patientes malignes et 357 bénignes, le jeu est légèrement déséquilibré, plus de patientes bénignes que malignes mais cela n'est pas dérangeant.

Les 30 features sont 10 propriétés du noyau cellulaire (rayon, texture, périmètre, aire, lissage, compacité, concavité, points concaves, symétrie, dimension fractale), chacune déclinée en trois statistiques calculées sur les noyaux d'une image : moyenne (mean_), erreur standard (_error) et pire valeur (worst_).

2.2 Lien entre les features et le diagnostic

J'ai réalisé deux graphiques pour voir si les mesures des noyaux sont liées au diagnostic.

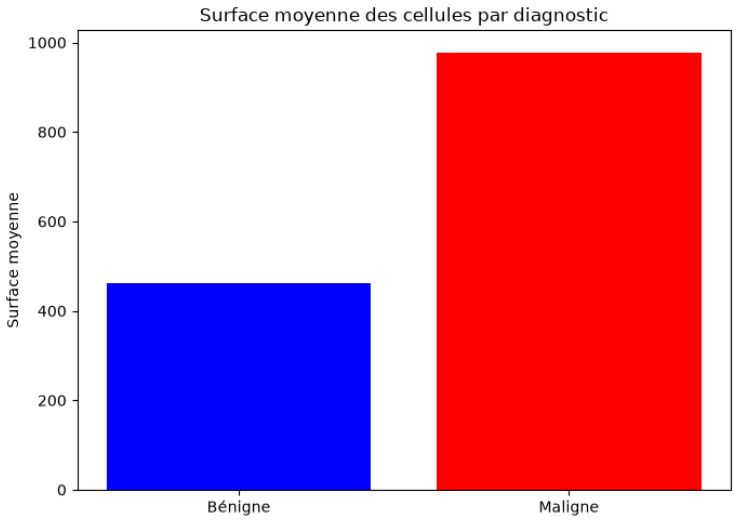


Figure 2 - Surface moyenne par diagnostic

La barre des tumeurs malignes est environ deux fois plus haute que celle des bénignes (~978 contre ~463). Les noyaux des tumeurs malignes sont donc en moyenne beaucoup plus grands. Cela va dans le même sens que la Figure 3, puisque l'aire dépend directement du rayon.

Mais ce graphique ne montre pas vraiment la moyenne de chaque groupe, certaines tumeurs malignes ont donc une petite surface qui peut se rapprocher de celle de bénignes.

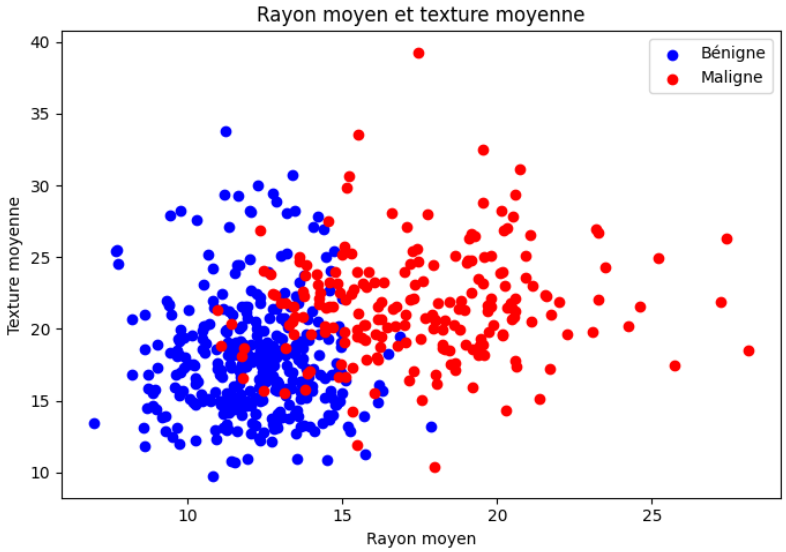


Figure 3 - Rayon moyen et texture moyenne selon le diagnostic

Les points bleus sont surtout à gauche, avec un rayon moyen entre 8 et 15. Les points rouges sont surtout à droite, avec un rayon entre 15 et 28. Plus le rayon est grand, plus la tumeur a de chances d'être maligne. Au-delà de 17, presque tous les points sont rouges. De plus, il y a une zone où les deux couleurs se mélangent, entre 12 et 16 environ. Dans cette zone, le rayon seul ne suffit pas pour décider.

Ainsi, le rayon est une mesure beaucoup plus liée au diagnostic que la texture. La séparation entre bénin et malin n'est pas parfaite avec ces deux mesures, donc il faudra plusieurs mesures pour bien classer.

Les deux graphiques disent la même chose : plus un noyau est grand (rayon, surface), plus la tumeur est souvent maligne. C'est plutôt logique, l'aire dépend directement du rayon. Les mesures de taille sont donc les plus liées au diagnostic, la texture l'est moins.

Cependant, aucune mesure seule ne sépare parfaitement les deux groupes, car ils se recouvrent en partie.

3. Méthode et protocole d'évaluation

Le code est séparé en trois fichiers : data_exploration.py (chargement et graphiques), golub_weighted.py (la méthode) et main.py (le processus complet).

- load_data lit le fichier, transforme le diagnostic en 0 (bénigne) et 1 (maligne), et supprime la colonne d'identifiant, qui n'apporte rien.

- golub_weighted_voting applique la méthode de Golub. Tout est calculé sur l'entraînement seulement : le poids de chaque feature, le choix des 10 meilleures et les milieux. Elle donne ensuite un score à chaque patiente de validation. Si le score est ≥ 0, elle prédit maligne.

- processus_entier lance la validation croisée (5 plis x 3 répétitions avec comme seed 24). Golub et la régression logistique sont testés sur exactement les mêmes découpages, donc la comparaison est juste. processus_entier est la fonction main du projet qui va appeler les

différentes fonctions de l'explorations des données, des calculs et des méthodes comme Golub, Jaccard etc...

Rentrons maintenant un peu plus dans les détails.

3.1 Vote pondéré de Golub

Sur le jeu d'entraînement seulement :

1/ Pour chaque mesure j, on calcule un poids : w_j = (moyenne des malignes - moyenne des bénignes) / (écart-type des malignes + écart-type des bénignes)

2/ On garde les 10 mesures avec le plus grand |w_j|

3/ Pour une patiente, on calcule un score : on additionne, pour chaque mesure gardée, le poids x (valeur - milieu des deux moyennes)

4/ Si le score est ≥ 0, on prédit maligne

3.2 Validation croisée

Nous utilisons RepeatedStratifiedKFold (5 plis, 3 répétitions, random_state = 24), soit 15 modèles. La seed est la somme jour + mois + année (deux derniers chiffres) de naissance donc 24 pour moi. Chaque ligne étant une patiente distincte, une patiente n'est jamais à la fois dans l'entraînement et la validation d'un même pli. Les deux méthodes sont évaluées sur exactement les mêmes 15 découpages, ce qui rend la comparaison équitable.

3.3 Métriques et modèle de comparaison

Pour chaque modèle : matrice de confusion, accuracy, accuracy équilibrée (moyenne de la sensibilité et de la spécificité) et AUC calculée sur le score continu v(x). Nous y ajoutons sensibilité (rappel de la classe maligne) et spécificité, plus parlantes cliniquement. La régression logistique (liblinear, C = 1,0, max_iter = 1000, sans pondération de classes ni réglage) utilise les 30 features, standardisées par un StandardScaler ajusté sur le pli d'entraînement seul, et prédit avec le seuil de probabilité 0,5.

4. Performances du vote pondéré

4.1 Premier split

Sur le premier découpage (455 patientes en entraînement, 114 en validation dont 43 malignes), nous obtenons les résultats suivants :

```
Exemple de résultats sur le premier split :

Golub - AUC :  0.9479, Régression Logistique - AUC :  0.9889

Golub - Balanced Acc :  0.9186, Régression Logistique - Balanced Acc :  0.9813

Golub - Sensibilité :  0.8372, Régression Logistique - Sensibilité :  0.9767

Golub - Spécificité :  1.0000, Régression Logistique - Spécificité :  0.9859
```

Figure 4 - Résultats comparaison pour premier split

La sensibilité (la part des tumeurs malignes qu'on repère) et la spécificité (la part des bénignes bien reconnues) sont calculées à partir de la matrice de confusion.

Pour Golub, la matrice de confusion est [[71, 0], [7, 36]] : aucune bénigne mal classée, mais 7 tumeurs malignes sur 43 classées bénignes (sensibilité 0,837). À titre de comparaison, la régression logistique donne 1 faux positif et 1 faux négatif.

Mais il est nécessaire d'effectuer ça sur un plus grand nombre de split pour avoir des résultats robustes sur lesquels ont peux s'appuyer.

4.2 Moyenne sur les 15 splits

```
Résultats moyens sur les 15 splits :

Golub Weighted Voting :
acc         0.888640
bal_acc     0.855576
auc         0.961663
sens        0.726098
spec        0.985055

Régression Logistique :
acc         0.977152
bal_acc     0.973174
auc         0.994736
sens        0.957512
spec        0.988837
```

Figure 5 - Résultats sur les 15 splits

Les résultats sont très reproductibles d'une répétition à l'autre (bal_acc de 0,889; 0,889 et 0,888 pour les trois répétitions). En revanche, la performance est asymétrique : la spécificité est bonne (0,985) mais la sensibilité est mauvaise (0,726). Le vote de Golub rate surtout des tumeurs malignes (174 faux négatifs cumulés sur les 15 plis de validation contre 16 faux positifs).

L'écart entre une AUC élevée (0,962) et une accuracy équilibrée plus faible (0,856) permet de savoir que le score v(x) ordonne bien les patientes, mais le seuil 0 (règle du milieu) est mal placé pour ces données. Je n'ai pas testé de seuil différent mais c'est une piste d'amélioration.

5. Stabilité de la sélection des features

```
Stabilité de la sélection de caractéristiques :

Fréquence de sélection sur les 15 splits :
  mean_radius: 15/15 (100.0%)
  mean_perimeter: 15/15 (100.0%)
  mean_area: 15/15 (100.0%)
  mean_concavity: 15/15 (100.0%)
  mean_concave_points: 15/15 (100.0%)
  worst_radius: 15/15 (100.0%)
  worst_perimeter: 15/15 (100.0%)
  worst_area: 15/15 (100.0%)
  worst_concave_points: 15/15 (100.0%)
  worst_concavity: 14/15 (93.3%)
  area_error: 1/15 (6.7%)
```

Figure 6 - Fréquence de sélection sur les 15 splits

L'indice de Jaccard moyen entre les 15 ensembles, calculé sur les 105 paires, vaut 0,976 (1 = ensembles identiques). La sélection est donc quasi identique d'un pli à l'autre : neuf features sont retenues dans les 15 plis, worst_concavity dans 14, et un seul pli la remplace par area_error.

Dans notre cas, la stabilité de la prédiction et des features choisies coïncident : la performance varie peu (écart-type de l'AUC de 0,015) et les features sont quasi toujours les mêmes.

Mais cette coïncidence ne prouve pas que le modèle est bon ni fiable, pour trois raisons :

- Le modèle est stable mais pas forcément bon, il rate trop de tumeurs malignes.
- Les features retenues sont surtout des déclinaisons de la taille (rayon, périmètre, aire, en version mean et worst) et de la concavité. Comme elles sont fortement corrélées, la sélection est stable parce qu'une même information est répétée, pas parce que dix informations indépendantes ont été trouvées. La sélection est aussi naturellement stable avec 569 patientes pour 30 variables, alors que Golub avait peu d'échantillons pour des milliers de gènes.
- L'aire est la mesure la plus importante, les autres mesures n'ont pas la même échelle (la concavité par exemple est minime). Le score Golub additionne les mesures sans les mettre à la même échelle. Une mesure avec de grands nombres pèse donc beaucoup plus dans le score qu'une mesure avec de petits nombres. Les mesures d'aire écrasent les autres. Le vote à 10 mesures est donc surtout un vote sur l'aire, et les autres mesures comptent très peu.

6. Comparaison avec la régression logistique

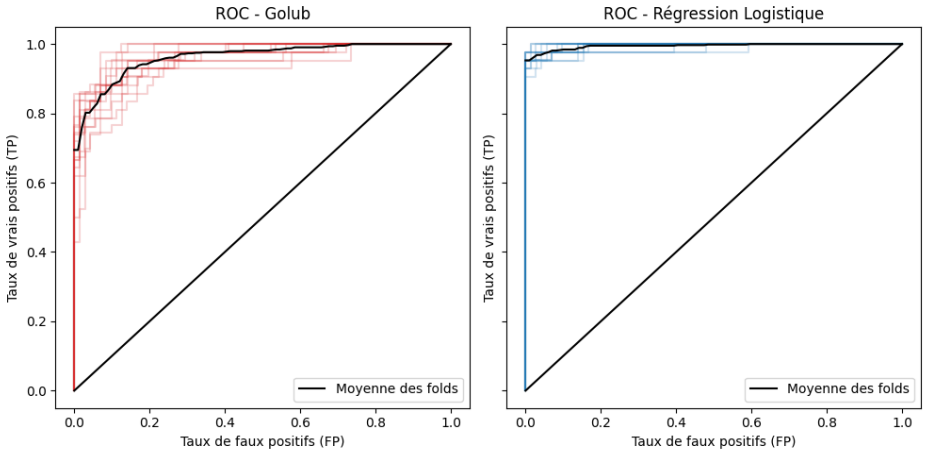


Figure 7 - Courbes ROC sur les 15 split, vote pondéré de Golub et régression logistique

La régression logistique est meilleure que Golub dans les 15 découpages sur 15, pour l'exactitude, l'exactitude équilibrée et l'AUC. Ses courbes ROC sont plus proches du coin en haut à gauche et plus serrées d'un pli à l'autre.

La grosse différence vient de la sensibilité (0,958 contre 0,726).

Cette différence vient des trois raisons que j'ai énuméré juste avant, la régression logistique met les mesures à la même échelle, utilise les 30 mesures et non pas les 10 « meilleures ».

Cependant, il y a des limites de comparaison. Je n'ai pas forcément bien effectué le protocole comme il fallait et ce n'est pas forcément optimisé, ni pour Golub et ni pour la régression logistique. Ce n'est pas le maximum que chaque méthode peut faire mais je pense que les résultats sont assez parlants pour dire que la régression logistique reste largement au-dessus de Golub.

7. Conclusion clinique

Est-ce que je recommande le vote de Golub pour prédire le diagnostic d'une patiente ?

Non, il nécessite des points d'amélioration.

Le modèle a de bons points : Il se trompe peu sur les tumeurs bénignes (spécificité de 0,985), donc il provoque peu de fausses alertes. Il classe bien les patientes dans l'ensemble (AUC de 0,962). Il est stable : les résultats varient peu d'un pli à l'autre, et les mêmes mesures sont choisies presque à chaque fois (Jaccard de 0,976).

Mais il a un gros défaut : il rate environ 1 tumeur maligne sur 4 (sensibilité de 0,726). En médecine, c'est l'erreur la plus grave. Une patiente avec un cancer classée bénigne peut être soignée trop tard. Un modèle utilisé pour aider au diagnostic doit trouver presque toutes les tumeurs malignes, quitte à faire quelques fausses alertes. Ici, c'est l'inverse : peu de fausses alertes, mais trop de cas manqués.

Tout cela peut être également expliqué par le fait que les données ne sont pas assez nombreuses, avec un dataset plus conséquent et plus de mesures le vote de Golub pourrait obtenir de meilleurs résultats.

La régression logistique, plus simple, trouve beaucoup plus de tumeurs malignes (sensibilité de 0,958) et se trompe moins dans l'ensemble. Il n'y a donc pas de raison médicale de préférer Golub sur ces données. Même la régression logistique ne suffirait pas seule pour écarter un cancer, car elle rate encore quelques cas.

8. Reproductibilité du papier de Golub et al.

Appliquer la méthode de Golub a été possible, parce que la formule du poids et la règle de vote sont courtes et claires. Mais je n'ai pas pu me baser seulement sur l'article : l'énoncé m'a donné la formule exacte, le nombre de mesures à garder (10) et la règle de décision.

On ne peut donc pas dire si l'article lui-même est reproductible, seulement que la méthode est applicable et que ses règles sont assez claires car je n'ai pas reproduit sur les mêmes données.

Grace au MANIFEST.json et au DATA_DICTIONARY.md, j'ai pu connaitre des informations importantes sur le dataset. Une explication sur chaque colonne et les limites du dataset.

En soit, je pense que si j'avais à ma disposition seulement le papier et le dataset, je n'aurais pas pu réaliser ce projet. Le sujet assignment 2 est clair et concis, le processus est détaillé ainsi que les formules bien renseignées. Le sujet permet de remettre en contexte le papier avec le nouveau dataset donc je me suis beaucoup plus appuyé dessus étant donné que c'est le travail à réaliser.

Cependant, le papier de Golub et al. n'est pas assez complet ce qui rend la reproductibilité plus complexe.

- Il manque le code et les données préparées, avec les identifiants des échantillons et les versions des logiciels

- Tester la méthode sur d'autres données et dire si cela peut fonctionner ou non

- Décrire plus clairement la préparation des données, formules et détails de calcul

9. Sources

- Le sujet : Assignment 2: Apply a published method to a new dataset

- Golub, T. R. et al. (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring : https://www.science.org/doi/10.1126/science.286.5439.531

- Wolberg, W., Mangasarian, O., Street, N. et Street, W. Breast Cancer Wisconsin (Diagnostic) : https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic

- RepeatedStratifiedKFold :https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RepeatedStratifiedKFold.html

- LogisticRegression : https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

- StandardScaler : https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html

- métriques ROC : https://scikit-learn.org/stable/modules/model_evaluation.html#receiver-operating-characteristic-roc

- Matrice de confusion : https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html